Отчёт по тестовому заданию «Постобработка OCR паспорта РФ»

Цель и принцип решения

Подготовлен детерминированный постпроцессор на Python. Для каждого OCR-документа он выбирает accept или reject: данные выдаются только при достаточных признаках корректности, а сомнительные документы отклоняются. Решение не требует обучения модели и не использует внешние сервисы.

Проверки включают уверенность и полноту распознанных полей, форматы и согласованность значений, даты, код подразделения и доступные данные MRZ, включая контрольные цифры и согласование данных между зонами. Для отдельных текстовых полей применяются дополнительные ограничения.

Результаты на train

На 3000 обучающих документов:

Принято верно: 96 (3,2%).
Принято с ошибкой: 0.
Ошибки по полям среди принятых: не обнаружены.

Почему выбрана консервативная стратегия

В этой задаче важно не только количество принятых документов, но и цена ошибки: если документ принят, система тем самым подтверждает, что распознанные персональные данные достаточно надёжны. Ошибочно принятый паспорт может быть опаснее, чем документ, который отклонён и отправлен на повторное сканирование или ручную проверку.

Поэтому стратегия сознательно предпочитает нулевое число ошибочных принятиям на train при низком покрытии, а не увеличение доли принятия за счёт сомнительных случаев. Низкое покрытие само по себе не является целью: пороги нужно подбирать на отдельной валидационной выборке, сопоставляя прирост принятия с риском ошибок. Ноль ошибок на train — наблюдаемый результат, но не гарантия нулевой ошибки на новых данных.

Обязательный прогноз для test

Для 2000 тестовых документов прогноз:
Будет принято: 75 (3,75%).
Будет принято с ошибкой: 0 (прогноз).

Поскольку разметка test недоступна, фактическое количество ошибок подтвердить нельзя; ноль — прогноз, а не измеренный результат.

Ограничения и вывод

Основной компромисс — низкая полнота ради снижения риска ложного принятия. Решение детерминированное, работает локально без интернета и не требует GPU; необходимы Python 3 и исходные файлы тестового задания. Следующий шаг — проверка на отложенной валидации и настройка порогов с явным приоритетом минимизации ошибочных принятиям.